# 豊田工業大学 課題研究報告書要旨

| 学部・学科 | 工学部 先端工学基礎学科                 |   |   |       |
|-------|------------------------------|---|---|-------|
| 学籍番号  | 12056                        | 氏 | 名 | 外山 洋太 |
| 題 名   | 文書・文間及びカテゴリ間の関係を考慮したレーティング予測 |   |   |       |

## 1 序論

企業はマーケティングのため自社商品の評判 分析を行う.商品の評価レーティング予測は評 判分析の重要な要素技術の一つである.その中 でも,商品レビューによるレーティング予測で は文字から文書に渡る様々な言語要素間の多様 で複雑な関係を考慮することが必要である.特 に,複数カテゴリにおけるレーティング予測に 関する従来手法 [1] は文間やカテゴリ間の関係 を十分に考慮できていなかった.本研究は,複 数カテゴリにおける評判分類について,文書及 び文間の関係とカテゴリ間の関係を同時に考慮 した分類の実現を目的とする.

# 2 関連研究

# 2.1 隠れ状態を用いたホテルレビューのレー ティング予測

藤谷ら [1] は複数のカテゴリにおける評判分類問題に対して、Multi-Instance Multi-Label learning for Relation Extraction (MIML-RE) [6] モデルを用いた手法を提案している。藤谷ら [1] は、文毎のレーティングからレビュー全体のレーティングを予測する際のカテゴリ間の繋がりを手調整によって変化させカテゴリ間の関係性を考慮している。しかし、この手法は文同士の位置関係を考慮していない。また、カテゴリ間については考慮しているものの複雑な関係性を捉えられていない。

# 2.2 パラグラフベクトル

文や文書といった大きな単位の言語要素の分散表現を学習する手法 [2] である. その手法のつつ, Distributed Memory model of Paragraph Vectors (PV-DM) によって得られたパラグラフベクトルは評判分類問題において高い正答率を示している [2]. しかし,文書全体にパラグラフベクトルを用いる場合,文同士の位置関係が分類時に考慮できない.

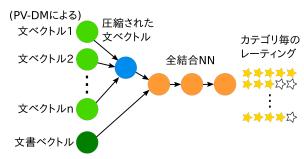


図 1: 提案手法による分類モデルの概略

2.3 ニューラルネットワークを用いた評判分析 ニューラルネットワークを用いた評判分析の 手法が, Nal ら [3], Rie ら [4], Duyu ら [5] 等に よって提案されている. これらの方法に共通するのは, 単語の意味表現から畳み込みニューラルネットワークと全結合ニューラルネットワークを用いて分類を行うことである.

これらの手法は1つのカテゴリにおける分類 問題を対象としている. つまり, 多カテゴリの 評判分類問題において, これらの手法により1 カテゴリ毎に分類問題を解くだけではカテゴリ 間の関係を考慮できない.

#### 3 提案手法

PV-DM によってレビュー内の文書全体及び 各文の分散表現を生成し、それらをニューラルネットワークの入力として分類を行う手法を提 案する. 文毎の意味表現を用いることで文同士 の位置関係を考慮し、全結合ニューラルネット ワークによる分類器を用いることで文間及びカテゴリ間の複雑な関係性を捉えることを目指す. 提案手法の入力はレビューである文書と正解 レーティングの組の集合、出力は各文書について予測されたカテゴリ毎のクラスである.

図1にモデルの概略を示す. 提案手法は,まず, PV-DM によって各レビューとそれに含まれる文の意味表現となるベクトルを生成する. 次に,各レビュー内の文ベクトルはレビュー毎に重み付け平均によって圧縮する. この過程により,レビュー毎に疎らだった文の数を統一す

る. 最後に、レビュー毎の文書ベクトルと圧縮 された文ベクトルの結合ベクトルを分類器の入 力層として分類を行う. 出力層の各ニューロン の出力値はあるカテゴリにおけるあるクラスの 正規化されていない対数確率を表す. 各カテゴ リ内で対数確率が最も高いクラスがそのカテゴ リの予測レーティングとなる.

#### 4 実験

#### 4.1 実験設定

提案手法が従来手法より優れていること,及び,文書ベクトルと文ベクトルを同時に用いることが評判分類に有効であることを示すため,各手法の正答率を測定した.比較手法として,(1)Quocら [2] による PV-DM,及び,提案手法における分類器の入力を (2) ASV (Averaged Sentence Vector) に変えた手法と (3) Weighted ASV に変えた手法を用いた.ASV とはレビュー内で平均した文ベクトルであり,Weighted ASV とはレビュー内で重み付け平均によって圧縮された文ベクトルである.データセットには,先行研究 [1] と同一の楽天トラベルにおけるレビューデータを用いた.

### 4.2 結果と考察

提案手法と3つの比較手法,従来手法[1]を正答率で比較したものを表1に示す.提案手法が従来手法[1]の正答率を0.0198だけp値0.00013で有意に上回っていることから,提案手法が従来手法[1]より正答率において優れていることが分かった.また,Weighted ASVの正答率がASVの正答率を0.0029だけp値0.028で有意に上回っていることから,文の位置関係の考慮がレーティング予測に有効であることが分かった.さらに,提案手法がPV-DMやWeighted ASVに比べ高い正答率を示していることから,

表 1: 各手法における正答率

| 手法           | 正答率    |
|--------------|--------|
| 従来手法 [1]     | 0.4832 |
| PV-DM        | 0.4980 |
| ASV          | 0.4838 |
| Weighted ASV | 0.4867 |
| 提案手法         | 0.5030 |

文書ベクトルと文ベクトルを同時に特徴量として用いることがレーティング予測に有効であることが分かった.

#### 5 結論

本研究では、多カテゴリにおける評判分類問題について、レビュー全体の文書ベクトルに加え重み付け平均された文ベクトルを用いた手法を提案した。実験では、提案手法が従来手法[1]より高い正答率を示した。また、比較手法の結果より、レビュー内の文の並びが評判分類に重要であることが分かった。

今後の課題は言語要素間のより多様で複雑な 関係を考慮することである.このためには,各 レビューの意味表現を生成するモデルと分類を 行うモデルを1つに統合する必要がある.なぜ ならば,モデルが分かれていることによって単 語や文字などのより小さな言語要素同士の関係 を分類時に考慮できないためである.モデルの 統一によって,学習手法の柔軟性を高めると共 にさらなる正答率の向上を目指す.

#### 参考文献

- [1] 藤谷宣典ら,隠れ状態を用いたホテルレビューのレーティング予測.言語処理学会第 21 回年次大会, 2015.
- [2] Quoc Le et al., Distributed representations of sentences and documents. ICML 2014, 2014.
- [3] Nal Kalchbrenner et al., A convolutional neural network for modelling sentences. ACL 2014, 2014.
- [4] Rie Johnson et al., Effective use of word order for text categorization with convolutional neural networks. NAACL 2015, 2015.
- [5] Duyu Tang et al., Learning semantic representation of users and products for document level sentiment classification. ACL 2015, 2015.
- [6] Mihai Surdeanu et al., Multi-instance multi-label learning for relation extraction. CoNLL 2012, 2012.